手計算
ニューラルネットワーク
入門　④実装1続き

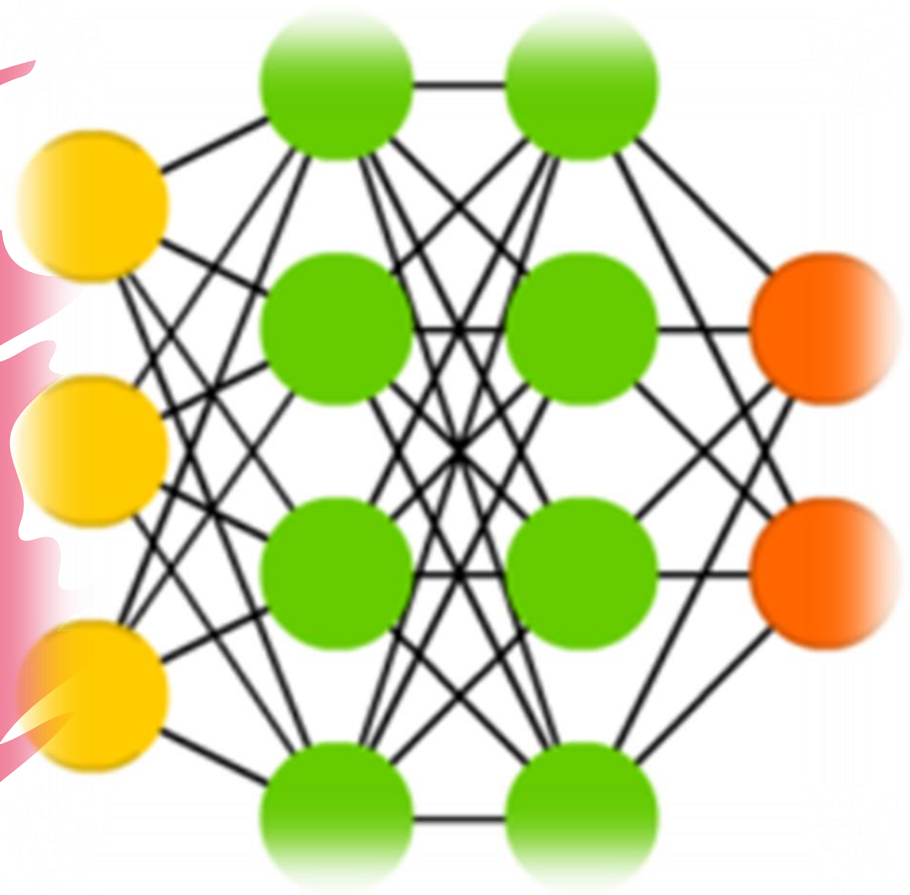

予定

第１回　理論：順伝播

第２回　理論：逆伝播

第３回　実装：実装1

第４回　実験：実装1の続き

第５回　実験：実装2iris,titanic

第６回　実験：実装3mnist

ニューラルネットワーク
を完全に理解したい

参考文献

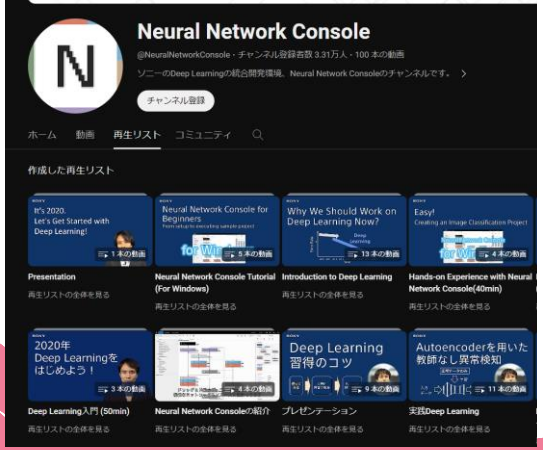
Neural Network Console
チャンネル登録
ホーム
動画
再生リスト
コミュニティ
作成した再生リスト
Presentation
Neural Network Console Tutorial (For Windows)
Introduction to Deep Learning
Hands-on Experience with Neural Network Console(40min)
2020年 Deep Learningをはじめよう！
Deep Learning習得のコツ
Autoencoderを用いた教師なし異常検知
Deep Learning入門 (50min)
Neural Network Consoleの紹介
プレゼンテーション
実践Deep Learning


微分の連鎖律の復習からはじめる
誤差逆伝播法
何が「誤差」で
何が「逆」なのか
丁寧に説明します
50:14


O'REILLY
オライリー・ジャパン
第2版
scikit-learn、Keras、
TensorFlowによる
実践機械学習
powered by
jupyter
Aurélien Géron 著
下田 倫大 監訳
長尾 高弘 訳

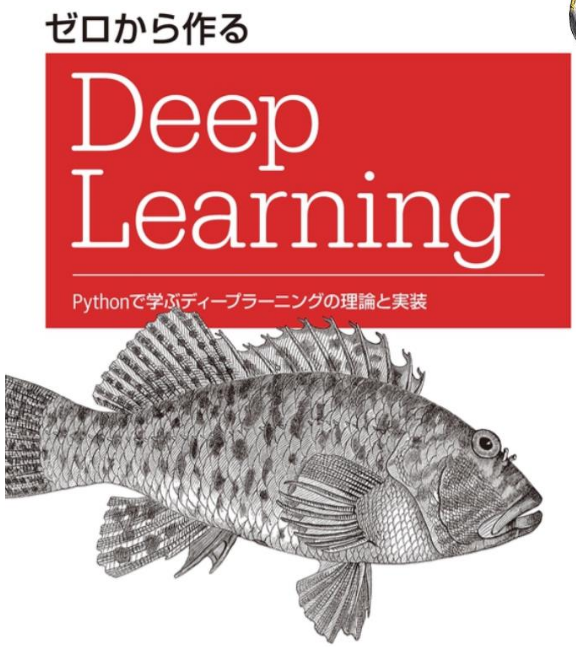
ゼロから作る
Deep
Learning
Pythonで学ぶディープラーニングの理論と実装

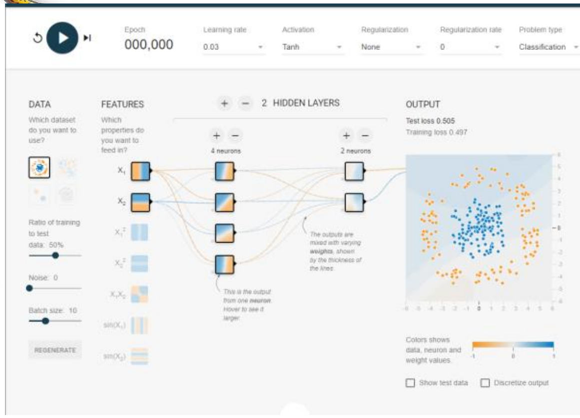
Epoch
000,000
Learning rate
Activation
Regularization
Regularization rate
Problem type
DATA
FEATURES
HIDDEN LAYERS
OUTPUT
REGENERATE


DEEP
LEARNING 入門
徹底解説
Part 0
初心者のため
の前準備
ディープラーニング入門：
仕組み理解から実装まで
某処生活_LiveSomewhere
5 本の動画 996 回視聴 最終更新日: 2021/02/28

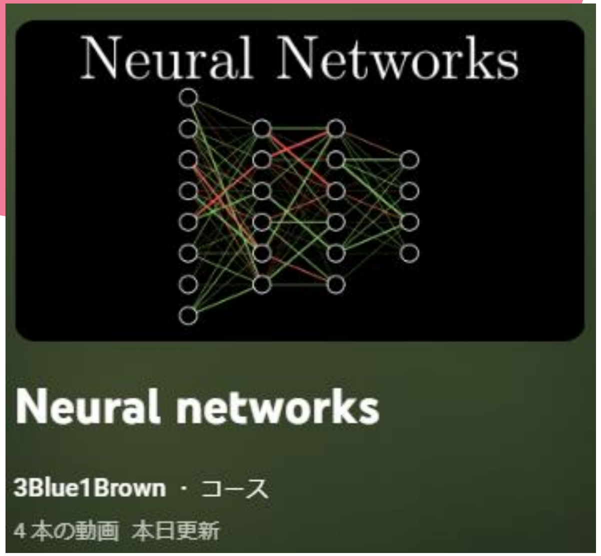
Neural Networks
Neural networks
3Blue1Brown・コース
4 本の動画 本日更新

前回のスライドの訂正

ミニバッチ学習のバイアス

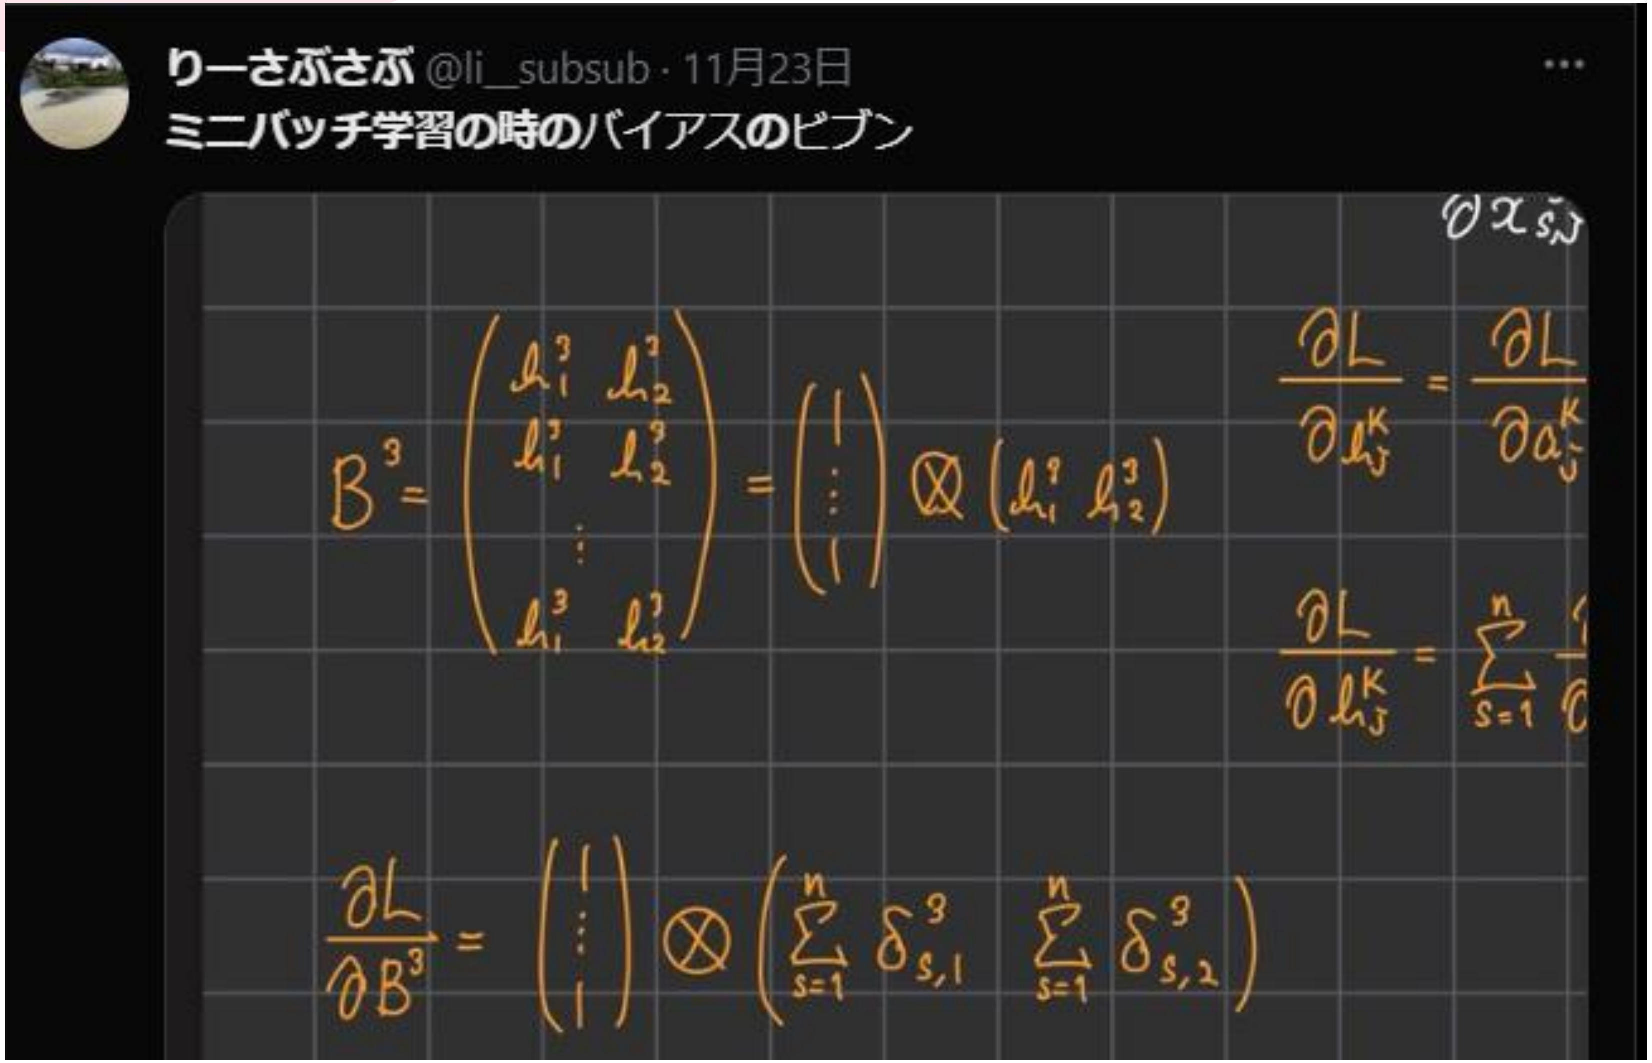

クロネッカー積

定義 [編集]

$A = (a_{ij})$ を $m \times n$ 行列、$B = (b_{kl})$ を $p \times q$ 行列とすると、それらのクロネッカー積 $A \otimes B$ は

$$A \otimes B = \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix}$$

で与えられる $mp \times nq$ 区分行列である。もっとはっきり成分を示せば、 $A \otimes B$ は

$$\begin{bmatrix}
a_{11}b_{11} & a_{11}b_{12} & \cdots & a_{11}b_{1q} & \cdots & \cdots & a_{1n}b_{11} & a_{1n}b_{12} & \cdots & a_{1n}b_{1q} \\
a_{11}b_{21} & a_{11}b_{22} & \cdots & a_{11}b_{2q} & \cdots & \cdots & a_{1n}b_{21} & a_{1n}b_{22} & \cdots & a_{1n}b_{2q} \\
\vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \vdots & \vdots & \ddots & \vdots \\
a_{11}b_{p1} & a_{11}b_{p2} & \cdots & a_{11}b_{pq} & \cdots & \cdots & a_{1n}b_{p1} & a_{1n}b_{p2} & \cdots & a_{1n}b_{pq} \\
\vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \vdots & \vdots & \ddots & \vdots \\
\vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \vdots & \vdots & \ddots & \vdots \\
a_{m1}b_{11} & a_{m1}b_{12} & \cdots & a_{m1}b_{1q} & \cdots & \cdots & a_{mn}b_{11} & a_{mn}b_{12} & \cdots & a_{mn}b_{1q} \\
a_{m1}b_{21} & a_{m1}b_{22} & \cdots & a_{m1}b_{2q} & \cdots & \cdots & a_{mn}b_{21} & a_{mn}b_{22} & \cdots & a_{mn}b_{2q} \\
\vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \vdots & \vdots & \ddots & \vdots \\
a_{m1}b_{p1} & a_{m1}b_{p2} & \cdots & a_{m1}b_{pq} & \cdots & \cdots & a_{mn}b_{p1} & a_{mn}b_{p2} & \cdots & a_{mn}b_{pq}
\end{bmatrix}$$

ミニバッチ学習のバイアス

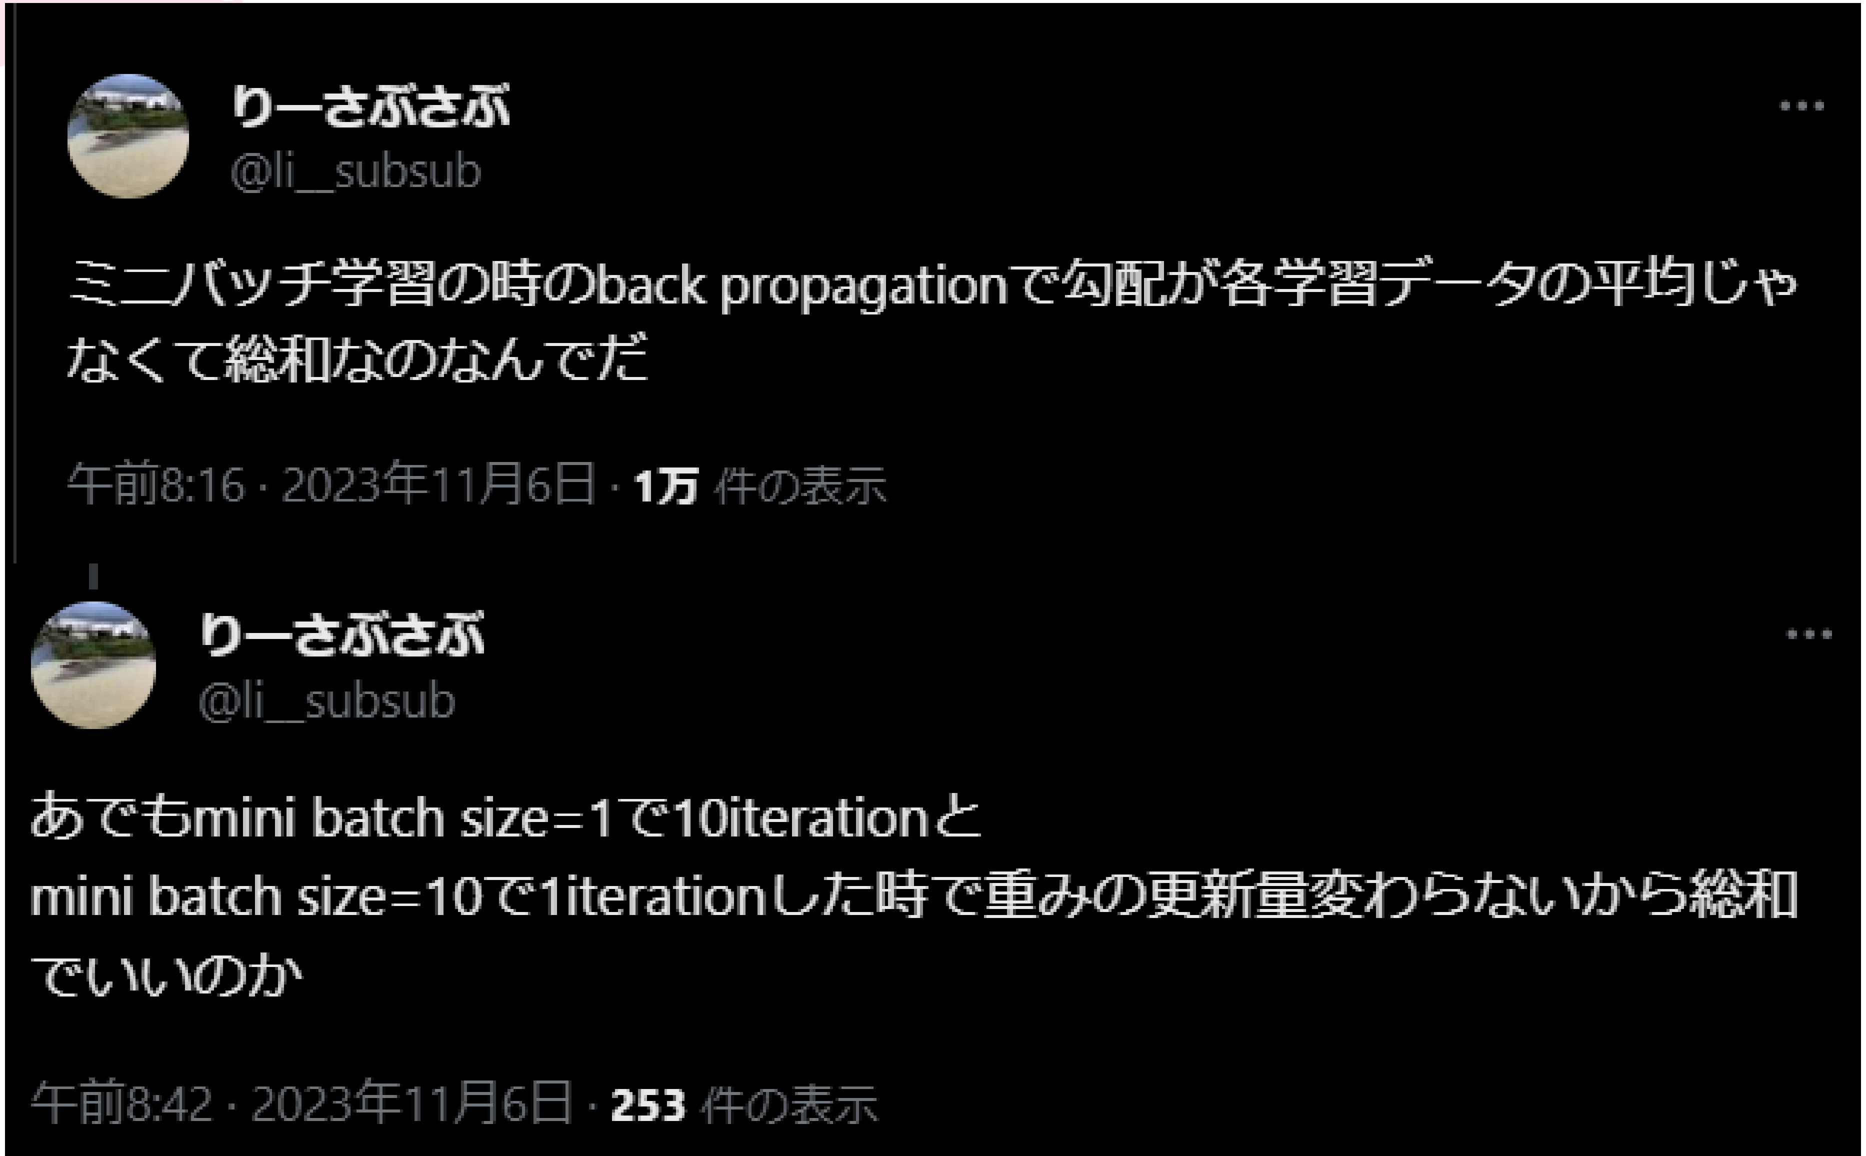

りーさぶさぶ
@li__subsub

ミニバッチ学習の時のback propagationで勾配が各学習データの平均じゃなくて総和なのなんでだ

午前8:16 · 2023年11月6日 · **1万** 件の表示

りーさぶさぶ
@li__subsub

あでもmini batch size=1で10iterationと
mini batch size=10で1iterationした時で重みの更新量変わらないから総和でいいのか

午前8:42 · 2023年11月6日 · **253** 件の表示

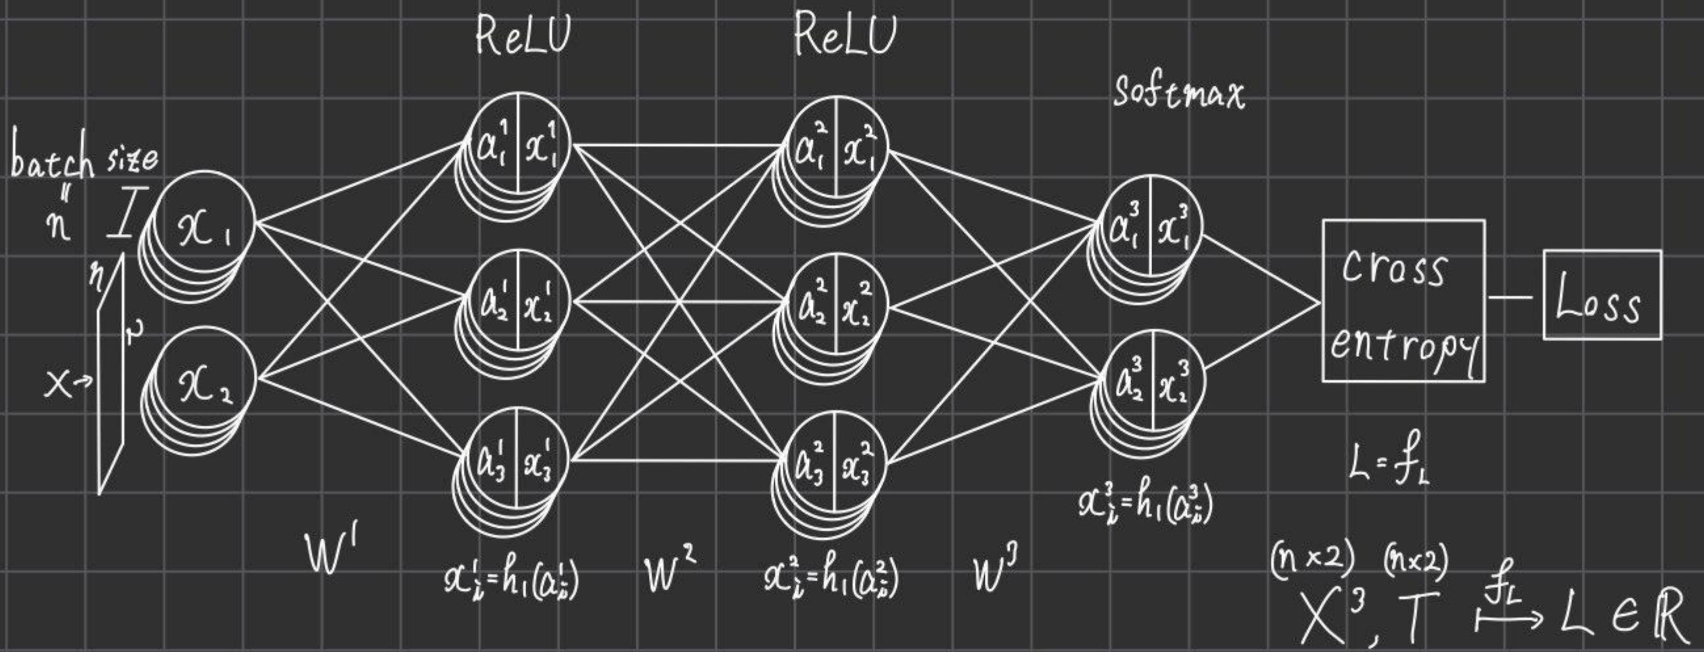

$$\frac{\partial L}{\partial W^2} = \begin{pmatrix} \frac{\partial L}{\partial w^2_{11}} & \frac{\partial L}{\partial w^2_{12}} & \frac{\partial L}{\partial w^2_{13}} \\ \frac{\partial L}{\partial w^2_{21}} & \frac{\partial L}{\partial w^2_{22}} & \frac{\partial L}{\partial w^2_{23}} \\ \frac{\partial L}{\partial w^2_{31}} & \frac{\partial L}{\partial w^2_{32}} & \frac{\partial L}{\partial w^2_{33}} \end{pmatrix} = \begin{pmatrix} \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,11}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,12}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,13}} \\ \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,21}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,22}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,23}} \\ \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,31}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,32}} & \sum_{s=1}^{n} \frac{\partial L}{\partial w^2_{s,33}} \end{pmatrix}$$

$$= \begin{pmatrix} x^1_{1,1} & x^1_{2,1} & & x^1_{n,1} \\ x^1_{1,2} & x^1_{2,2} & \cdots & x^1_{n,2} \\ x^1_{1,3} & x^1_{2,3} & & x^1_{n,3} \end{pmatrix} \begin{pmatrix} \delta^2_{1,1} & \delta^2_{1,2} & \delta^2_{1,3} \\ \delta^2_{2,1} & \delta^2_{2,2} & \delta^2_{2,3} \\ & \vdots & \\ \delta^2_{n,1} & \delta^2_{n,2} & \delta^2_{n,3} \end{pmatrix} = X^{1^T} \Delta^2$$

$$\delta^2_{s,j} = h_2'(a^2_{s,j}) \sum_k \delta^3_{s,k} w^3_{jk} \quad \therefore \Delta^2 = \frac{\partial h_2}{\partial A^2} \odot \Delta^3 W^{3T}$$

$$\frac{\partial L}{\partial W^2} = \begin{pmatrix} \frac{\partial L}{\partial w_{11}^2} & \frac{\partial L}{\partial w_{12}^2} & \frac{\partial L}{\partial w_{13}^2} \\ \frac{\partial L}{\partial w_{21}^2} & \frac{\partial L}{\partial w_{22}^2} & \frac{\partial L}{\partial w_{23}^2} \\ \frac{\partial L}{\partial w_{31}^2} & \frac{\partial L}{\partial w_{32}^2} & \frac{\partial L}{\partial w_{33}^2} \end{pmatrix} = \begin{pmatrix} \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,11}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,12}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,13}^2} \\ \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,21}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,22}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,23}^2} \\ \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,31}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,32}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,33}^2} \end{pmatrix}$$

$$= \begin{pmatrix} x_{1,1}^1 & x_{2,1}^1 & & x_{n,1}^1 \\ x_{1,2}^1 & x_{2,2}^1 & \cdots & x_{n,2}^1 \\ x_{1,3}^1 & x_{2,3}^1 & & x_{n,3}^1 \end{pmatrix} \begin{pmatrix} \delta_{1,1}^2 & \delta_{1,2}^2 & \delta_{1,3}^2 \\ \delta_{2,1}^2 & \delta_{2,2}^2 & \delta_{2,3}^2 \\ & \vdots & \\ \delta_{n,1}^2 & \delta_{n,2}^2 & \delta_{n,3}^2 \end{pmatrix} = X^{1^T} \Delta^2$$

$$\delta_{s,j}^2 = h_2'(a_{s,j}^2) \sum_k \delta_{s,k}^3 w_{jk}^3 \quad \therefore \Delta^2 = \frac{\partial h_2}{\partial A^2} \odot \Delta^3 W^{3^T}$$

$$\frac{\partial L}{\partial W^1} = \begin{pmatrix} \frac{\partial L}{\partial w_{11}^2} & \frac{\partial L}{\partial w_{12}^2} & \frac{\partial L}{\partial w_{13}^2} \\ \frac{\partial L}{\partial w_{21}^2} & \frac{\partial L}{\partial w_{22}^2} & \frac{\partial L}{\partial w_{23}^2} \end{pmatrix} = \begin{pmatrix} \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,11}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,12}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,13}^2} \\ \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,21}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,22}^2} & \sum_{s=1}^{n} \frac{\partial L}{\partial w_{s,23}^2} \end{pmatrix}$$

$$= \begin{pmatrix} x_{1,1}^1 & x_{2,1}^1 & \cdots & x_{n,1}^1 \\ x_{1,2}^1 & x_{2,2}^1 & & x_{n,2}^1 \end{pmatrix} \begin{pmatrix} \delta_{1,1}^2 & \delta_{1,2}^2 \\ \delta_{2,1}^2 & \delta_{2,2}^2 \\ \vdots & \\ \delta_{n,1}^2 & \delta_{n,2}^2 \end{pmatrix} = X^{0^T} \Delta^1$$

$$\Delta^1 = \frac{\partial h_1}{\partial A^1} \odot \Delta^2 W^{2^T}$$

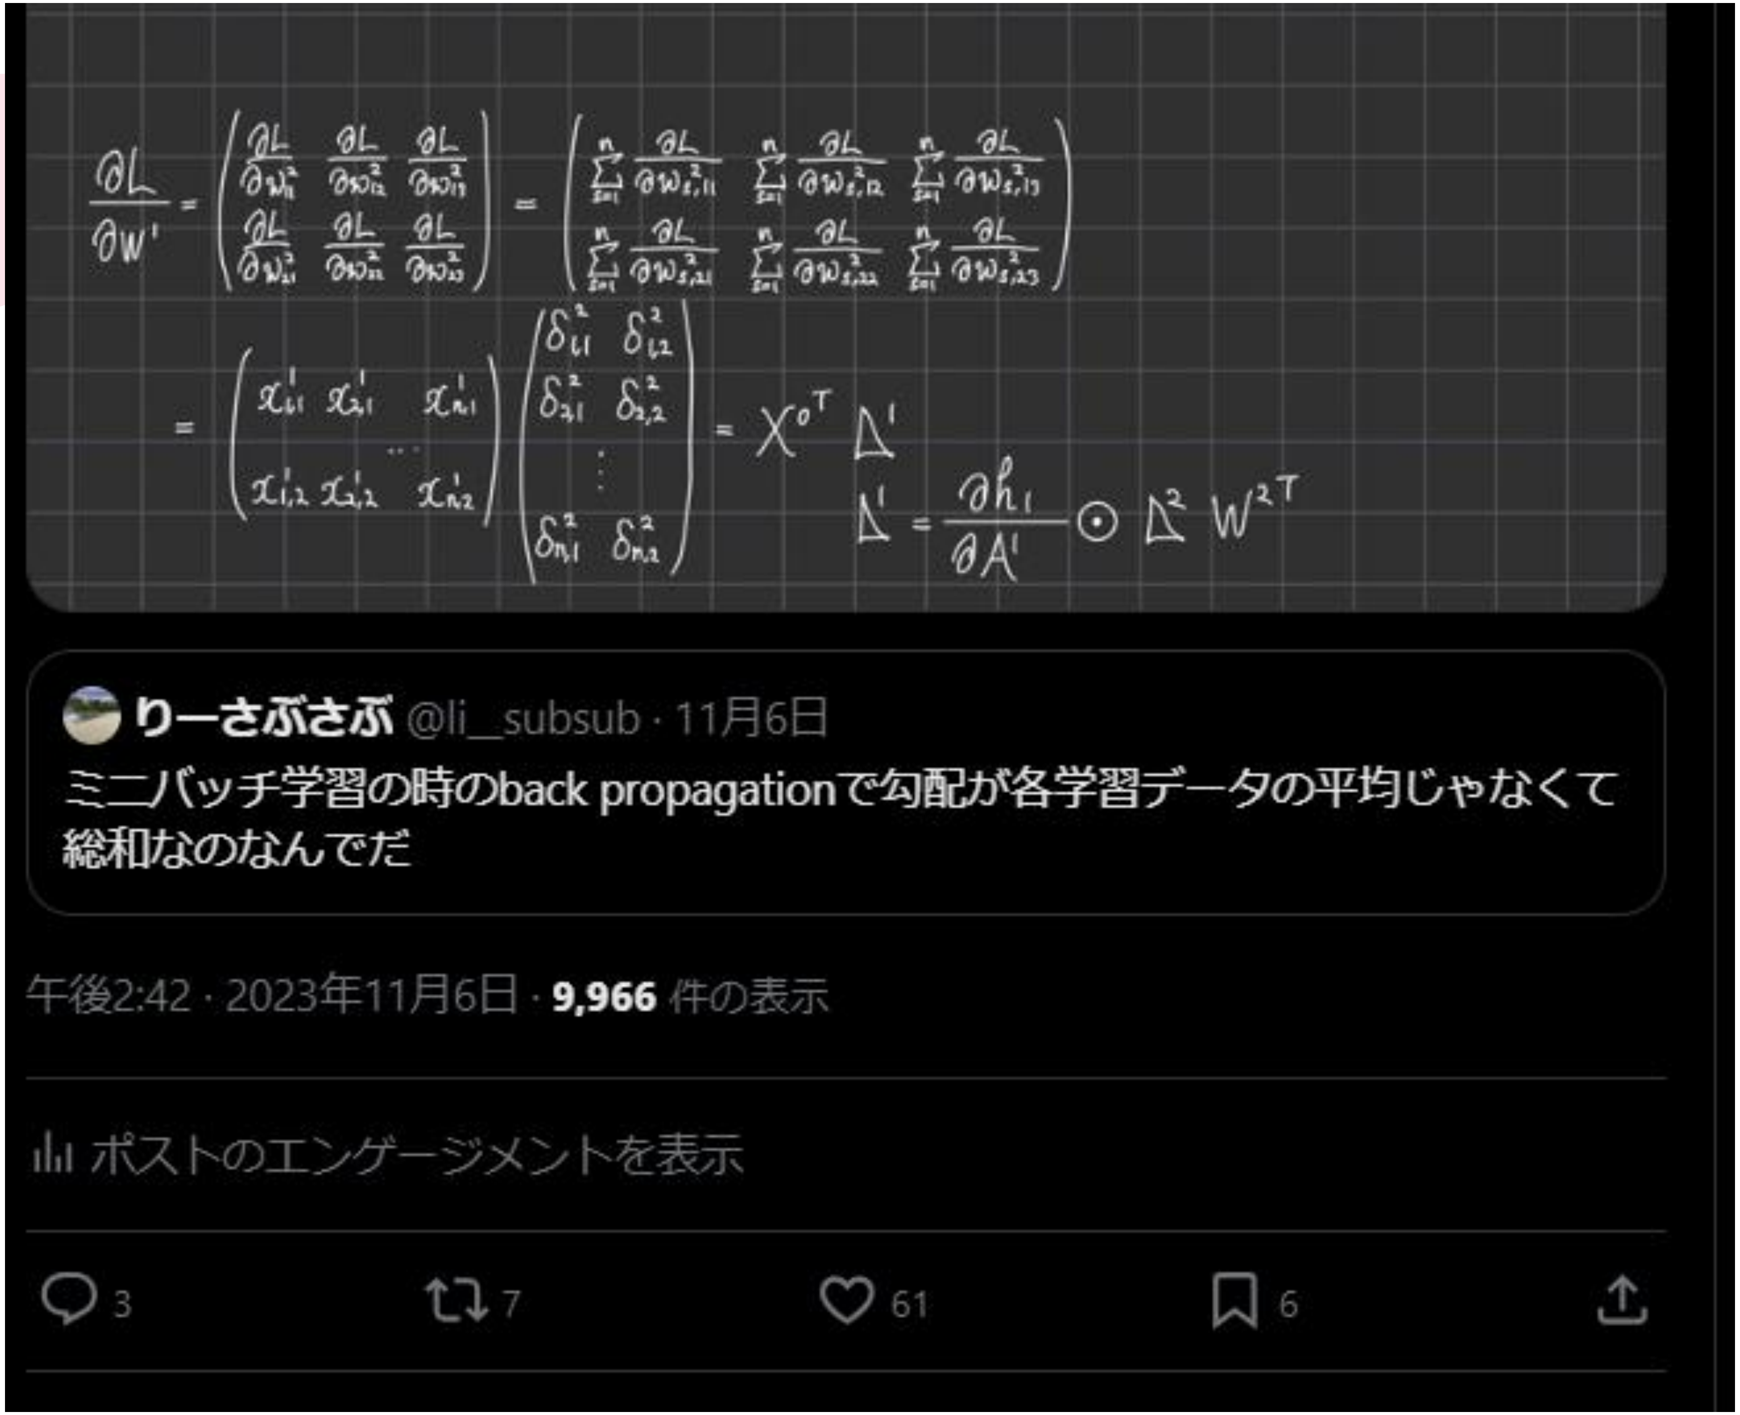
りーさぶさぶ @li_subsub · 11月6日
ミニバッチ学習の時のback propagationで勾配が各学習データの平均じゃなくて総和なのなんでだ
午後2:42 · 2023年11月6日 · 9,966 件の表示
ポストのエンゲージメントを表示
3
7
61
6

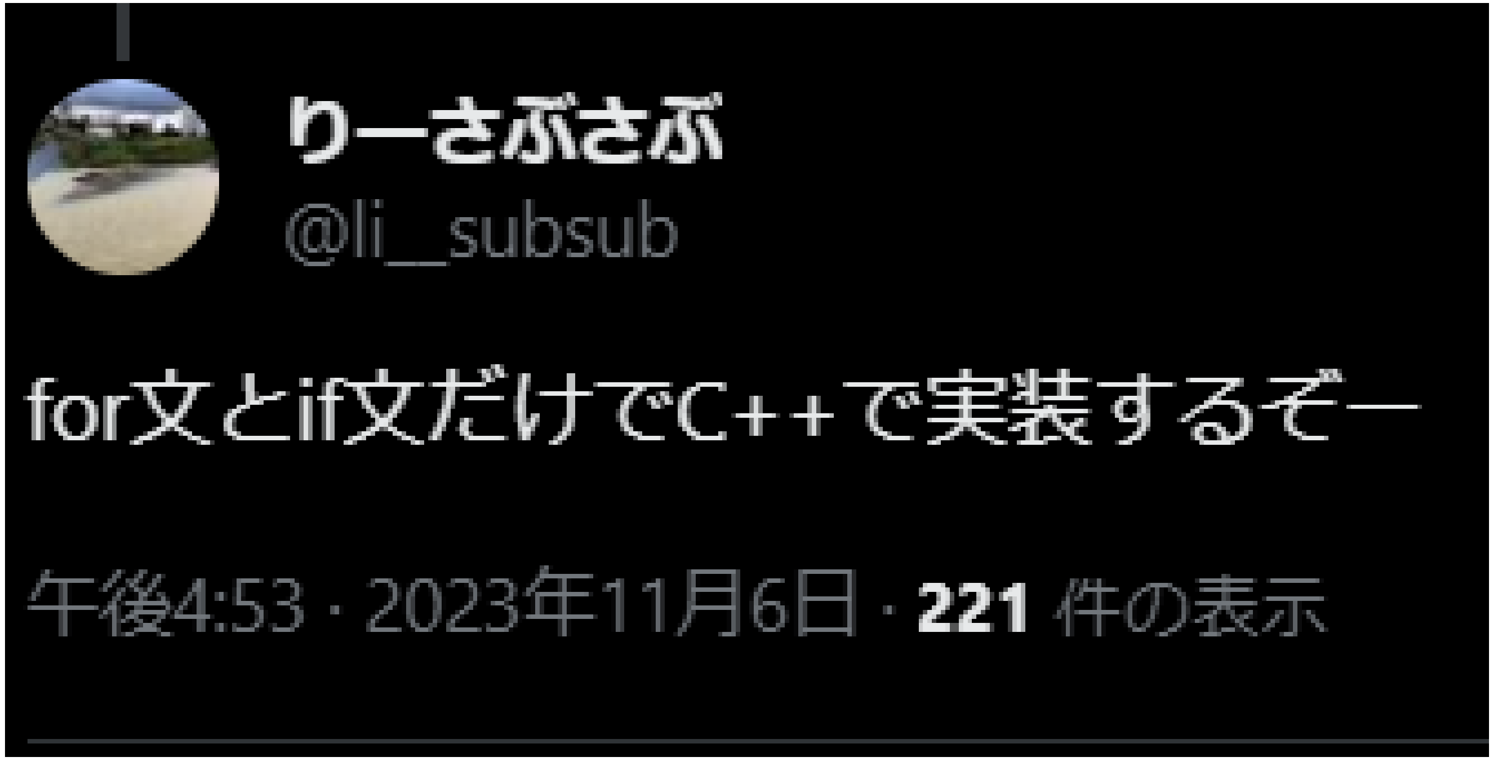
りーさぶさぶ
@li__subsub
for文とif文だけでC++で実装するぞー
午後4:53 · 2023年11月6日 · 221 件の表示

遠い昔

実装
前回の続きから

誤差逆伝播に必要な関数の実装

誤差関数の微分
今回はcross entropy

$$CE = f_L = -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m} t_{ij}\log x_{ij}$$

$$\frac{\partial f_L}{\partial x_{pq}} = -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m} t_{ij}\frac{\partial}{\partial x_{pq}}(\log x_{ij})$$

$$= -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m} \frac{t_{ij}}{x_{ij}}\frac{\partial x_{ij}}{\partial x_{pq}}$$

$$\frac{\partial x_{ij}}{\partial x_{pq}} = \begin{cases} 0(p \neq i) \\ 1(p = i, q = j) \\ -1(p = i, q \neq j) \end{cases}$$

$\frac{\partial f_L}{\partial X}$(n行m列)の行列を返す関数を作成

```
vvd calc_r_cross_entropy(vvd &x, vvd &t) {
    //ここに書く
}
```

誤差逆伝播に必要な関数の実装

```
vvd calc_r_cross_entropy(vvd &x, vvd &t) {
    int n = x.size(), m = x[0].size();
    vvd tmp(n, vd(m, 0));
    for (int s=0; s<n; ++s) {
        for (int j=0; j<m; ++j) {
            for (int k=0; k<m; ++k) {
                if (j == k) tmp[s][j] -= t[s][j] / x[s][j];
                else tmp[s][j] += t[s][k] / (x[s][k]);
            }
            tmp[s][j] /= n;
        }
    }
    return tmp;
}
```

誤差逆伝播に必要な関数の実装

（とあるsインスタンス目に対して）

$$\frac{\partial {x_{s,i}}^K}{\partial {a_{s,j}}^K} = {x_{s,i}}^K\left(1 - {x_{s,j}}^K\right), i = j$$

$$\frac{\partial {x_{s,i}}^K}{\partial {a_{s,j}}^K} = {x_{s,i}}^K\left(0 - {x_{s,j}}^K\right), i \neq j$$

softmaxの微分

$$\frac{\partial h_K}{\partial A^K} = \left(\left(\left(\begin{pmatrix} \frac{\partial {x_{1,1}}^K}{\partial {a_{1,1}}^K} & \cdots & \frac{\partial {x_{1,1}}^K}{\partial {a_{1,3}}^K} \\ \vdots & \ddots & \vdots \\ \frac{\partial {x_{1,3}}^K}{\partial {a_{1,1}}^K} & \cdots & \frac{\partial {x_{1,3}}^K}{\partial {a_{1,3}}^K} \end{pmatrix}\right)\right)\right) \cdots$$

n個

$\frac{\partial h_K}{\partial A^K}$(n層？m行m列)のテンソルを返す関数を作成

```
//rx_k/ra_j
//m class 分類
//m次正方行列を返す
vvvd calc_r_softmax(vvd &x) {
    //ここに書く
}
```

がmini-batch個あるテンソルを返す

誤差逆伝播に必要な関数の実装

```cpp
vvvd calc_r_softmax(vvd &x) {
    int n = x.size(), m = x[0].size();
    vvvd ret(n, vvd(m, vd(m, 0)));
    for (int s=0; s<n; ++s) {
        for (int i=0; i<m; ++i) {
            for (int j=0; j<m; ++j) {
                if (i == j) ret[s][i][j] = x[s][i]*(1 - x[s][j]);
                else ret[s][i][j] = x[s][i]*(0 - x[s][j]);
            }
        }
    }
    return ret;
}
```

誤差逆伝播に必要な関数の実装

ReLUの微分

$$ReLU(x) = \begin{cases} x(x > 0) \\ 0(x \leq 0) \end{cases}$$

$\frac{\partial h_l}{\partial A^l}$(n行m列)の行列
を返す関数を作成

```
vvd calc_r_ReLU (vvd &a) {
    //ここに書く
}
```

誤差逆伝播に必要な関数の実装

```
vvd calc_r_ReLU (vvd &a) {
    int n = a.size(), m = a[0].size();
    vvd tmp(n, vd(m, 0));
    for (int s=0; s<n; ++s) {
        for (int j=0; j<m; ++j) {
            if (a[s][j] >= 0) tmp[s][j] = 1;
        }
    }
    return tmp;
}
```

誤差逆伝播に必要な関数の実装

バイアスの微分

$$B^3 = \begin{pmatrix} l_1^3 & l_2^3 \\ l_1^3 & l_2^3 \\ \vdots & \\ l_1^3 & l_2^3 \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \otimes \begin{pmatrix} l_1^3 & l_2^3 \end{pmatrix}$$

$$\frac{\partial L}{\partial B^3} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \otimes \begin{pmatrix} \sum_{s=1}^{n} \delta_{s,1}^3 & \sum_{s=1}^{n} \delta_{s,2}^3 \end{pmatrix}$$

$\frac{\partial L}{\partial B^l}$(n行m列)の行列
を返す関数を作成

```
vvd calc_r_bias (vvd &delta) {
    //ここに書く
}
```

誤差逆伝播に必要な関数の実装

```
vvd calc_r_bias (vvd &delta) {
    int n = delta.size(), m = delta[0].size();
    vvd rb;
    if (n != delta.size() || m != delta[0].size()) cout << "size is not match" <<
    rb.assign(1, vd(m, 0));
    for (int j=0; j<m; ++j) {
        for (int i=0; i<n; ++i) {
            rb[0][j] += delta[i][j];
        }
    }
    rb = expansion_bias(rb, n);
    return rb;
}
```

順伝播の実装

入力 X^0 $(n \times 2)$

$$A^1 = X^0 W^1 + B^1$$

$$X^1 = \mathrm{ReLU}(A^1)$$

$$A^2 = X^1 W^2 + B^2$$

$$X^2 = \mathrm{ReLU}(A^2)$$

$$A^3 = X^2 W^3 + B^3$$

$$X^3 = \mathrm{SoftMax}(A^3)$$

$$L = \mathrm{CrossEntropy}(X^3)$$

```
//forward propagation
for (int k=0; k<depth; ++k) {
    //ここに書く
}
```

逆伝播の実装

```
//back propagation
for (int k=depth-1; k>=0; --k) {
    //ここに書く
}
```

誤差逆伝播-公式 まとめ 行列表現

出力層

$$\frac{\partial L}{\partial W^K} = X^{(K-1)T}\Delta^K$$

$$\frac{\partial L}{\partial B^K} = \begin{pmatrix}1\\ \vdots\\ 1\end{pmatrix} \otimes \left(\sum_i \delta_{i,1}{}^K \quad \sum_i \delta_{i,2}{}^K \quad \sum_i \delta_{i,3}{}^K\right)$$

$$\Delta^K = \frac{\partial f_L}{\partial X^K} \odot \frac{\partial h_K}{\partial A^K}$$

中間層

$$\frac{\partial L}{\partial W^l} = X^{(l-1)T}\Delta^l$$

$$\frac{\partial L}{\partial B^l} = \begin{pmatrix}1\\ \vdots\\ 1\end{pmatrix} \otimes \left(\sum_i \delta_{i,1}{}^l \quad \sum_i \delta_{i,2}{}^l \quad \sum_i \delta_{i,3}{}^l\right)$$

$$\Delta^l = \Delta^{l+1} W^{(l+1)T} \odot \frac{\partial h_l}{\partial A^l}$$

訓練のテクニック

バッチ学習：すべての訓練インスタンスを一気に学習に用いる

必ず極小値に収束する

訓練インスタンスが大量だと時間にかかる

訓練インスタンスが数百GBだとそもそもパソコンに収まらない.

訓練のテクニック

ミニバッチ学習：訓練インスタンスの一部を学習に用いる
オンライン学習：訓練インスタンス１つを学習に用いる

訓練インスタンスが大量でも一部をパソコンにロードして
学習して捨てて，またロードすればいい→アウトオブコア学習

極小値の近くで行ったり来たりしちゃうかも
→学習計画

訓練のテクニック

学習計画
学習が進むにつれて，学習率の値を小さくする
いつか学習率が0になるのでパラメータの更新が起きなくなる
そこが極小値付近なら収束が見込める

訓練のテクニック

Momentum

$v \leftarrow \alpha v - \eta \frac{\partial L}{\partial W}$　　　v：速度，α：空気抵抗　0.9など

$W \leftarrow W + v$

AdaGrad

学習係数を減衰させる

はじめ大→次第に小

適応的 Adaptive

$h \leftarrow h + \frac{\partial L}{\partial W} \odot \frac{\partial L}{\partial W}$

$W \leftarrow W - \eta \frac{1}{\sqrt{h}} \frac{\partial L}{\partial W}$

Adam ≈ Momentum + AdaGrad (2015)

訓練のテクニック

```
int main() {
    vvd x, t;
    double eta = 0.03, attenuation = 0.6;
    int n = 1000;
    int show_interval = 1000;
    int learning_plan = 2000;
    int loop = 9500;//9500
    int batch_size = 100;
```

学習計画
今回は単に適当なタイミングで
公比をかけて小さくする

```
//学習率の更新
if ((i+1) % learning_plan == 0) eta *= attenuation;
```

実装

プログラム動いた？
いい感じのハイパーパラメータを見つけてみよう
手でGrid Searchをする
ちなpython↓

```
from sklearn.model_selection import GridSearchCV

param_grid = [{'weights': ["uniform", "distance"], 'n_neighbors': [3, 4, 5]}]

knn_clf = KNeighborsClassifier()
grid_search = GridSearchCV(knn_clf, param_grid, cv=5, verbose=3)
grid_search.fit(X_train, y_train)
```

実装の確認

train_setも初見のtest_setにも適用したモデルができた
モデル：ハイパーパラメータとパラメータの総称，作ったAIそのもの

テストセットを可視化してみる
mainの最後のこれのコメントアウトを外す

```
//一旦csvに出力したのちpythonで描画してみる
// drawing_by_python(nn, depth);
```

実装の確認

```
void drawing_by_python(vector<layer_t> &nn, int depth) {
    vvd data;
    for (int i=0; i<depth; ++i) {
        nn[i].b = expansion_bias(nn[i].b, 1);
    }
    for (double x=-6; x<=6; x+=1) {
        for (double y=-6; y<=6; y+=1) {
            vvd tmp = {{x, y}};
            //forward propagation
            for (int k=0; k<depth; ++k) {
                if (k == 0) nn[k].a = matrix_add(matrix_multi(tmp, nn[k].w), nn[k].b);
                else nn[k].a = matrix_add(matrix_multi(nn[k-1].x, nn[k].w), nn[k].b);
                // if (k < depth-1) nn[k].x = hm_ReLU(nn[k].a);
                if (k < depth-1) nn[k].x = hm_tanh(nn[k].a);
                else nn[k].x = hm_softmax(nn[k].a);
            }
```

```
            vvd tmp = {{x, y}};
            //forward propagation
            for (int k=0; k<depth; ++k) {
                if (k == 0) nn[k].a = matrix_add(matrix_multi(tmp, nn[k].w), nn[k].b);
                else nn[k].a = matrix_add(matrix_multi(nn[k-1].x, nn[k].w), nn[k].b);
                // if (k < depth-1) nn[k].x = hm_ReLU(nn[k].a);
                if (k < depth-1) nn[k].x = hm_tanh(nn[k].a);
                else nn[k].x = hm_softmax(nn[k].a);
            }
            if (nn[depth-1].x[0][0] > nn[depth-1].x[0][1]) {
                //inside
                tmp[0].push_back(1);
            } else {
                //outside
                tmp[0].push_back(0);
            }
            data.push_back(tmp[0]);
        }
    }
    outputfile(data);
}
```

実装の確認

```cpp
//x, y, tを列挙
void outputfile(const vvd &output) {
    int n = output.size(), m = output[0].size();
    string fname = "circle_.csv";
    ofstream outputFile (fname);

    for (int i=0; i<n; ++i) {
        for (int j=0; j<m; ++j) {
            outputFile << output[i][j];
            if (j != m-1) outputFile << ", ";
        }
        outputFile << endl;
    }
}
```

```
-2, -4, 0
-2, -3, 0
-2, -2, 1
-2, -1, 1
-2, 0, 1
-2, 1, 1
-2, 2, 1
-2, 3, 0
```

circle_.csv

実装の確認

You

以下のpythonの2次元配列です.
[x座標,y座標,ラベル]の列になっています.
matpotlib.pyplotのscatterを使って，ラベルが0.0なら青，ラベルが1.0ならオレンジ色で2次元座標にプロットしてください.

[[1.0, -6.0, 0.0], [1.0, -5.0, 0.0], [1.0, -4.0, 0.0], [1.0, -3.0, 0.0], [1.0, -2.0, 1.0], [1.0, -1.0, 1.0], [1.0, 0.0, 1.0], [1.0, 1.0, 1.0]]

drawing.py 1文字も書いてないけどできた

実装の確認　感動を味わってほしいところ

```cpp
void drawing_by_python(vector<layer_t> &nn, int depth) {
    vvd data;
    for (int i=0; i<depth; ++i) {
        nn[i].b = expansion_bias(nn[i].b, 1);
    }
    for (double x=-6; x<=6; x+=1) {
        for (double y=-6; y<=6; y+=1) {
```

点の差分を1→0.05にする　.cppを実行

実装の確認　感動を味わってほしいところ

```
30    # 散布図をプロット
31    plt.scatter(x_values, y_values, c=colors, s=20)
```

点のサイズs=20→1に変更　.pyを実行

実装の確認　感動を味わってほしい演習

中間層の活性化関数をReLUじゃなくてtanhにする
ACTIVATIONに以下を追記

```
double h_tanh(double x) {
    return (exp(x)-exp(-x)) / (exp(x)+exp(-x));
}
vvd hm_tanh(vvd &x) {
    int n = x.size(), m = x[0].size();
    vvd tmp(n, vd(m));
    for (int i=0; i<n; ++i) {
        for (int j=0; j<m; ++j) {
            tmp[i][j] = h_tanh(x[i][j]);
        }
    }
    return tmp;
}
```

実装の確認　感動を味わってほしい演習

中間層の活性化関数をReLUじゃなくてtanhにする
BACK PROPAGATIONに以下を追記

```
vvd calc_r_tanh(vvd &a) {
    int n = a.size(), m = a[0].size();
    vvd tmp(n, vd(m, 0));
    for (int s=0; s<n; ++s) {
        for (int j=0; j<m; ++j) {
            tmp[s][j] = 長い
        }
    }
    return tmp;
}
```

実装の確認　感動を味わってほしい演習

中間層の活性化関数をReLUじゃなくてtanhにする
MAINの順伝播・逆伝播
tarin_setの順伝播・test_setの順伝播
drawing_by_python関数内の

ReLUの部分を適切にtanhに書き直す
（関数の部分だけで大丈夫だと思う）

C++実行→Python実行

実装の確認　感動を味わってほしい演習

judge_term関数を編集して（すぐ下に書いてある）
xorのような分類器・線形分離可能な分類器が正しく
動作することを確認する

多クラス分類とone-hot表現

出力層が1ノードでクラスの番号（整数）を予測するようにすると
class2をclass1と誤認識した場合の誤差と
class3をclass1と誤認識した場合の誤差が
異なる.
→対等なクラス分類でも”近さ”的な要らない概念が出てきちゃう

class1:{1, 0, 0}
class2:{0, 1, 0}
class3:{0, 0, 1}
としてcross entropyをすればクラス同士に何の順序も生まれない

宿題 4class分類

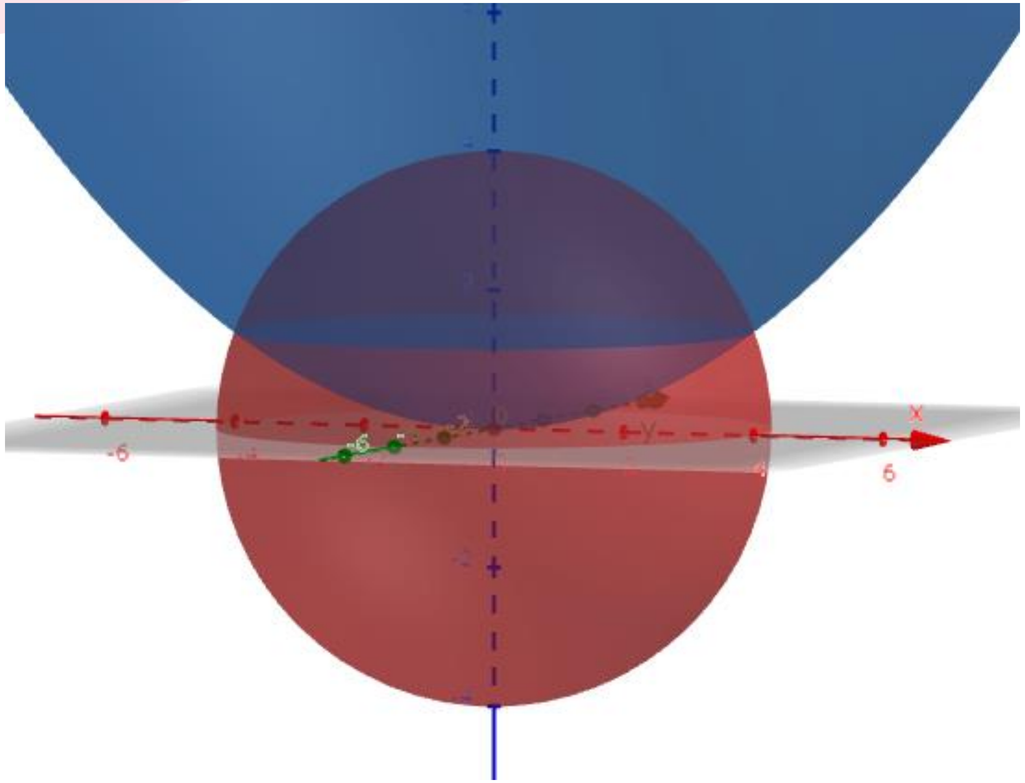

$$x^2 + y^2 + z^2 = 16$$

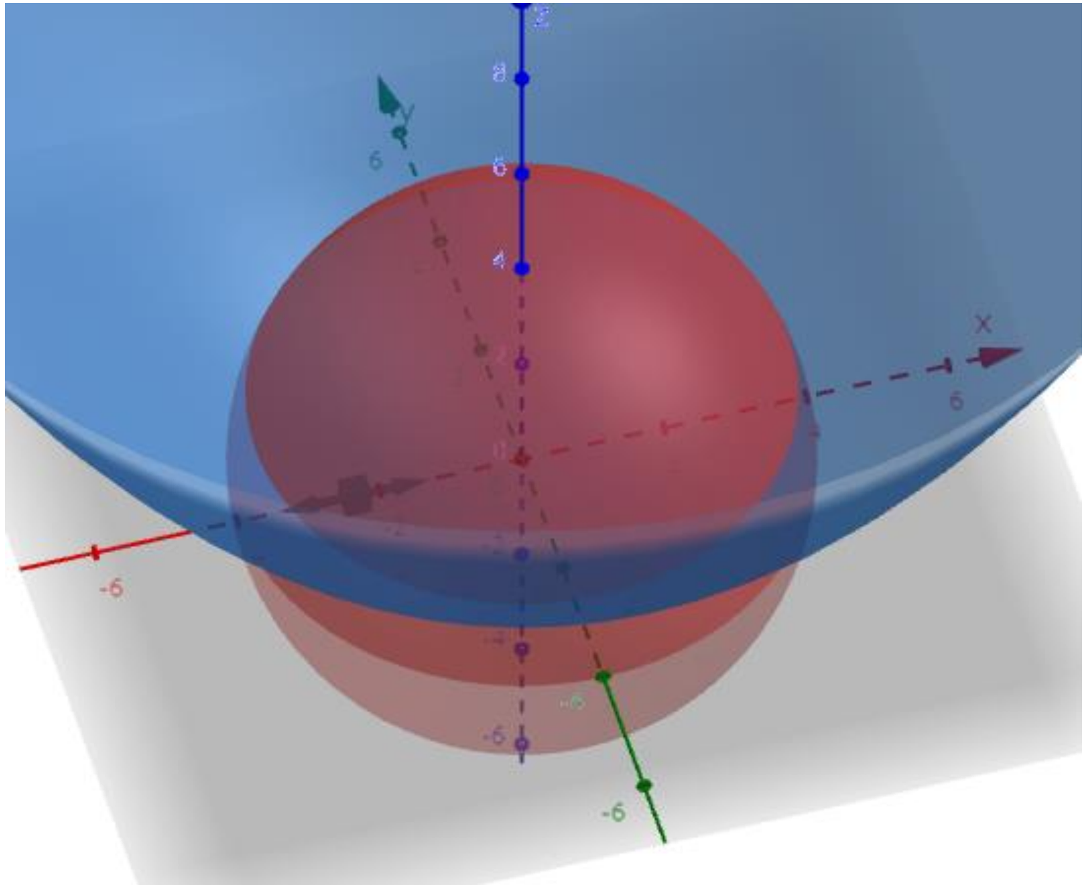

$$z = \frac{1}{10}(x^2 + y^2)$$

宿題 4class分類

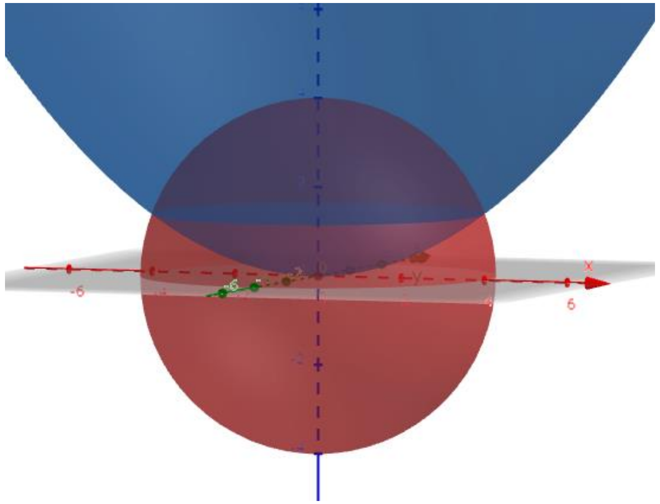

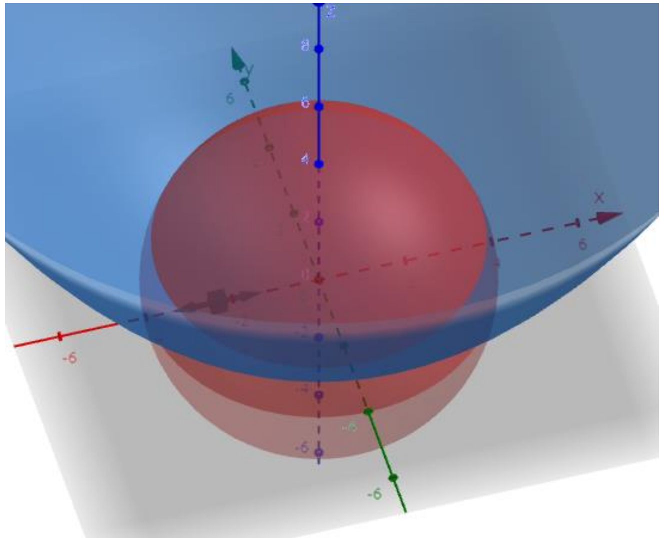

インスタンス：特徴量(x,y,z)を持つ
すべてのインスタンスは
|x|<6, |y|<6, |z|<6の立方体の内側

class1:球の中かつ放物面の上(z>放物面)
class2:球の中かつ放物面の下
class3:球の外かつ放物面の上
class4:球の外かつ放物面の下